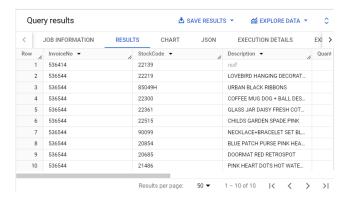
# 고객을 세그먼테이션하자 [프로젝트]

## 11-2. 데이터 불러오기

### 데이터 살펴보기

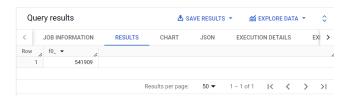
• 테이블에 있는 10개의 행만 출력하기

```
-- 10개 행 출력
SELECT *
FROM uplifted-sphinx-439401-k5.modulabs_project.data
LIMIT 10;
```



• 전체 데이터는 몇 행으로 구성되어 있는지 확인하기

```
-- 전체 행의 개수 출력
SELECT count(*)
FROM uplifted-sphinx-439401-k5.modulabs_project.data;
```



## 데이터 수 세기

• COUNT 함수를 사용해서, 각 컬럼 별 데이터 포인트의 수를 세어 보기

count(Country) AS COUNT\_CustomerID
FROM `uplifted-sphinx-439401-k5.modulabs\_project.data`;



## 11-4. 데이터 전처리 방법(1): 결측치 제거

#### 컬럼 별 누락된 값의 비율 계산

- 각 컬럼 별 누락된 값의 비율을 계산
  - $\circ$  각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기

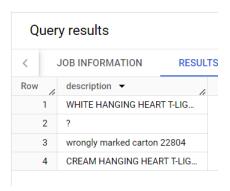
```
-- 컬럼 별 누락된 값의 비율 계산
SELECT column_name, ROUND((total - column_value) / total * 100, 2)
FROM
   SELECT 'InvoiceNo' AS column_name, COUNT(InvoiceNo) AS column_value, COUNT(*) AS total FROM `u
plifted-sphinx-439401-k5.modulabs_project.data` UNION ALL
   SELECT 'StockCode' AS column_name, COUNT(StockCode) AS column_value, COUNT(*) AS total FROM `u
plifted-sphinx-439401-k5.modulabs_project.data` UNION ALL
   SELECT 'Description' AS column_name, COUNT(Description) AS column_value, COUNT(*) AS total FRO
M `uplifted-sphinx-439401-k5.modulabs_project.data` UNION ALL
   SELECT 'Quantity' AS column_name, COUNT(Quantity) AS column_value, COUNT(*) AS total FROM `upl
ifted-sphinx-439401-k5.modulabs_project.data` UNION ALL
   SELECT 'InvoiceDate' AS column_name, COUNT(InvoiceDate) AS column_value, COUNT(*) AS total FRO
M `uplifted-sphinx-439401-k5.modulabs_project.data` UNION ALL
   SELECT 'UnitPrice' AS column_name, COUNT(UnitPrice) AS column_value, COUNT(*) AS total FROM `u
plifted-sphinx-439401-k5.modulabs_project.data` UNION ALL
   SELECT 'CustomerID' AS column_name, COUNT(CustomerID) AS column_value, COUNT(*) AS total FROM
`uplifted-sphinx-439401-k5.modulabs_project.data` UNION ALL
    SELECT 'Country' AS column_name, COUNT(Country) AS column_value, COUNT(*) AS total FROM `uplif
ted-sphinx-439401-k5.modulabs_project.data`
) AS column data
ORDER BY 2 DESC;
```

Query results					
JOB INFORMATION		RESULTS	CHART	JSON	
Row	column_name ▼	6	f0_ <b>▼</b>	/	
1	CustomerID			24.93	
2	Description			0.27	
3	Country			0.0	
4	InvoiceDate			0.0	
5	UnitPrice			0.0	
6	Quantity			0.0	
7	InvoiceNo			0.0	
8	StockCode			0.0	

## 결측치 처리 전략

• StockCode = '85123A' 의 Description 을 추출하는 쿼리문을 작성하기

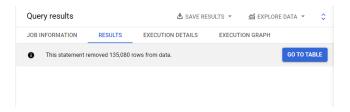
```
-- StockCode = '85123A'을 만족하는 Description 컬럼
SELECT DISTINCT description
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
WHERE StockCode = '85123A';
```



## 결측치 처리

• DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시

```
-- 결측치 데이터 삭제
DELETE FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
WHERE description IS NULL
OR customerID IS NULL
```



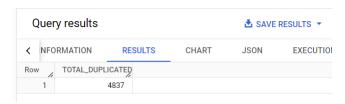
# 11-5. 데이터 전처리(2): 중복값 처리

#### 중복값 확인

- 중복된 행의 수를 세어보기
  - 。 8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기

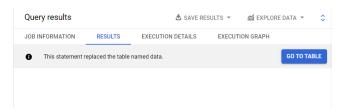
```
CustomerID,
Country

HAVING DUPLICATED_ROWS > 1
)
SELECT count(DUPLICATED_ROWS) AS TOTAL_DUPLICATED
FROM CHECK_DUPLICATED_ROWS;
```



#### 중복값 처리

- 중복값을 제거하는 쿼리문 작성하기
  - CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(\*)을 DISTINCT 한 데이터로 업데이트

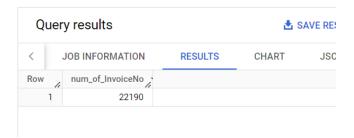


# 11-6. 데이터 전처리(3): 오류값 처리

#### InvoiceNo 살펴보기

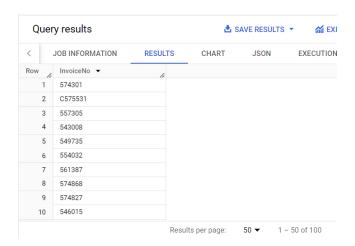
• 고유(unique)한 InvoiceNo 의 개수를 출력하기

```
-- 고유(unique)한 InvoiceNo의 개수를 출력
SELECT count(DISTINCT InvoiceNo) AS num_of_InvoiceNo
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
```



#### • 고유한 <u>InvoiceNo</u> 를 앞에서부터 100개를 출력하기

-- 고유한 InvoiceNo를 앞에서부터 100개를 출력 SELECT DISTINCT InvoiceNo FROM `uplifted-sphinx-439401-k5.modulabs\_project.data` LIMIT 100;



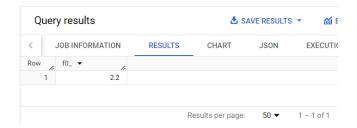
• InvoiceNo 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)

-- InvoiceNo가 'C'로 시작하는 행을 필터링(100개) SELECT \* FROM `uplifted-sphinx-439401-k5.modulabs\_project.data` WHERE InvoiceNo LIKE 'C%' LIMIT 100;



• 구매 건 상태가 Canceled 인 데이터의 비율(%) - 소수점 첫번째 자리까지

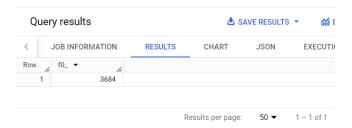
-- 구매 건 상태가 Canceled 인 데이터의 비율(%) SELECT ROUND(SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END) / COUNT(\*) \*100, 1) FROM `uplifted-sphinx-439401-k5.modulabs\_project.data`



## StockCode 살펴보기

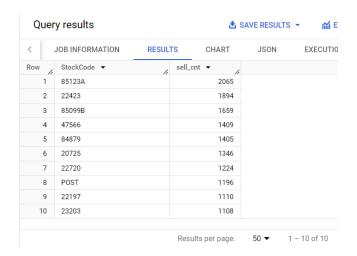
• 고유한 StockCode 의 개수를 출력하기

```
-- 고유한 StockCode의 개수를 출력
SELECT count(DISTINCT StockCode)
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
```



- 어떤 제품이 가장 많이 판매되었는지 보기 위하여 StockCode 별 등장 빈도를 출력하기
  - 。 상위 10개의 제품들을 출력하기

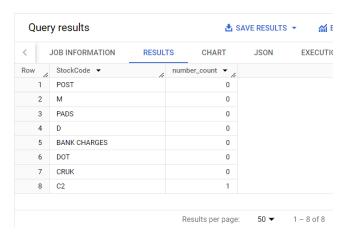
```
-- StockCode 별 등장 빈도를 출력(상위10개)
SELECT StockCode, COUNT(*) AS sell_cnt
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY StockCode
ORDER BY sell_cnt DESC
LIMIT 10;
```



• StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고

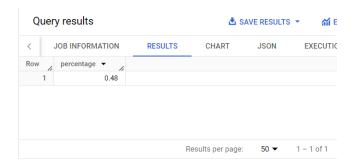
○ **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
-- 숫자가 0~1개인 값들에는 어떤 코드들이 들어가 있는지를 확인
SELECT DISTINCT StockCode, number_count
FROM (
SELECT StockCode,
LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
)
WHERE number_count = 0
OR number_count = 1;
```



- StockCode 의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
  - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
-- 해당 코드 값들을 가지고 있는 데이터 수가 전체 데이터 에서 차지하는 퍼센트
SELECT
ROUND(SUM(CASE WHEN number_count = 0 OR number_count = 1 THEN 1 ELSE 0 END)/COUNT(*)*100, 2) AS
percentage
FROM (
SELECT StockCode,
LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
);
```



• 제품과 관련되지 않은 거래 기록을 제거하기

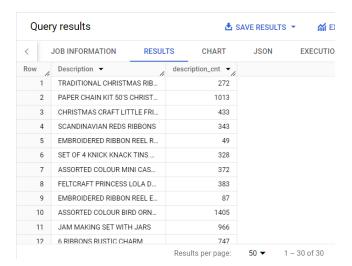
```
-- 제품과 관련되지 않은 거래 기록을 제거
DELETE FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
WHERE StockCode IN (
```

```
SELECT DISTINCT StockCode
FROM ( SELECT StockCode,
   LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
   FROM `uplifted-sphinx-439401-k5.modulabs_project.data`)
WHERE number_count = 0 OR number_count = 1
);
```

### Description 살펴보기

• 고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기

```
-- 고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력
SELECT Description, COUNT(*) AS description_cnt
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY Description
LIMIT 30;
```



• 서비스 관련 정보를 포함하는 행들을 제거하기

```
-- 서비스 관련 정보를 포함하는 행들을 제거
-- 'Next Day Carriage'나'High Resolution Image'를 포함하는 행 제거
DELETE
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
WHERE description IN ('Next Day Carriage','High Resolution Image');
```



• 대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기

```
-- 대소문자를 혼합하고 있는 데이터를 대문자로 표준화

CREATE OR REPLACE TABLE `uplifted-sphinx-439401-k5.modulabs_project.data` AS

SELECT * EXCEPT (Description),

UPPER(Description) AS Description

FROM `uplifted-sphinx-439401-k5.modulabs_project.data`;
```



## UnitPrice 살펴보기

• UnitPrice 의 최솟값, 최댓값, 평균을 구하기

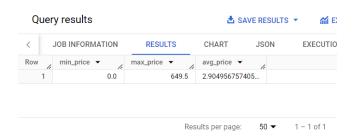
```
-- UnitPrice의 최솟값, 최댓값, 평균

SELECT min(UnitPrice) AS min_price,

    max(UnitPrice) AS max_price,

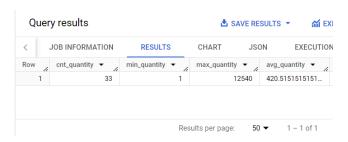
    avg(UnitPrice) AS avg_price

FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
```



• 단가가 0원인 거래의 개수, 구매 수량( Quantity )의 최솟값, 최댓값, 평균 구하기

```
-- 단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균
SELECT count(Quantity) AS cnt_quantity,
    min(Quantity) AS min_quantity,
    max(Quantity) AS max_quantity,
    avg(Quantity) AS avg_quantity
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
WHERE UnitPrice = 0;
```



• UnitPrice = 0 를 제거하고 일관된 데이터셋을 유지하기

```
-- UnitPrice = 0 제거
CREATE OR REPLACE TABLE `uplifted-sphinx-439401-k5.modulabs_project.data` AS
SELECT *
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
WHERE UnitPrice != 0;
```



## 11-7. RFM 스코어

### Recency

• InvoiceDate 컬럼을 연월일 자료형으로 변경하기

```
-- InvoiceDate 컬럼을 연월일 자료형으로 변경
SELECT DATE(InVoiceDate) AS InvoiceDay, *
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`;
```

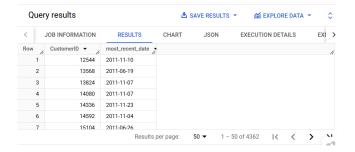


• 가장 최근 구매 일자를 MAX() 함수로 찾아보기



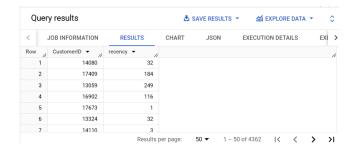
• 유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기

```
-- 유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장
SELECT CustomerID, max(DATE(InVoiceDate)) AS most_recent_date
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID;
```



• 가장 최근 일자( most\_recent\_date )와 유저별 마지막 구매일( InvoiceDay )간의 차이를 계산하기

```
-- 가장 최근 일자(most_recent_date)와 유저별 마지막 구매일(InvoiceDay)간의 차이를 계산
SELECT
CustomerID,
EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
SELECT
CustomerID,
MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID
);
```



• 최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 user\_r 이라는 이름의 테이블로 저장하기

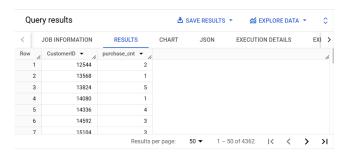
```
-- 지금까지의 결과를 user_r이라는 이름의 테이블로 저장
CREATE OR REPLACE TABLE `uplifted-sphinx-439401-k5.modulabs_project.user_r` AS
SELECT
   CustomerID,
   EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
   SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID
);
```



## **Frequency**

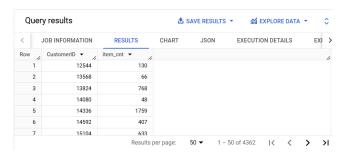
• 고객마다 고유한 InvoiceNo의 수를 세어보기

```
-- 고객마다 고유한 InvoiceNo의 수
SELECT
CustomerID,
count(DISTINCT InvoiceNo) AS purchase_cnt
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID;
```



• 각 고객 별로 구매한 아이템의 총 수량 더하기

```
-- 각 고객 별로 구매한 아이템의 총 수량
SELECT
CustomerID,
sum(quantity) AS item_cnt
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID;
```



• 전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 user\_rf 라는 이름의 테이블에 저장하기

```
-- 1,2를 합쳐 user_rf라는 이름의 테이블에 저장
CREATE OR REPLACE TABLE `uplifted-sphinx-439401-k5.modulabs_project.user_rf` AS

-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
SELECT
   CustomerID,
   count(DISTINCT InvoiceNo) AS purchase_cnt
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID
),
-- (2) 구매한 아이템 총 수량 계산
```

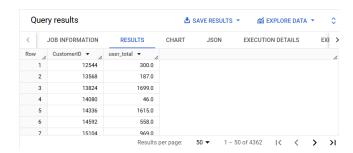
```
item_cnt AS (
SELECT
  CustomerID,
  sum(quantity) AS item_cnt
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID
)
-- 기존의 user_r에 (1)과 (2)를 통합
SELECT
  pc.CustomerID,
  pc.purchase_cnt,
 ic.item_cnt,
 ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
JOIN `uplifted-sphinx-439401-k5.modulabs_project.user_r` AS ur
  ON pc.CustomerID = ur.CustomerID;
```



#### Monetary

• 고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)

```
-- 고객별 총 지출액 계산
-- 소수점 첫째 자리에서 반올림
SELECT
CustomerID,
round(sum(Quantity*UnitPrice)) AS user_total
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID;
```



- 고객별 평균 거래 금액 계산
  - 고객별 평균 거래 금액을 구하기 위해 1) data 테이블을 user\_rf 테이블과 조인(LEFT JOIN) 한 후, 2) purchase\_cnt 로 나누어서 3) user\_rfm 테이블로 저장하기

```
-- user_rfm 테이블로 저장
CREATE OR REPLACE TABLE `uplifted-sphinx-439401-k5.modulabs_project.user_rfm` AS
SELECT
```

```
rf.CustomerID AS CustomerID,
rf.purchase_cnt,
rf.item_cnt,
rf.recency,
ut.user_total,
ut.user_total / purchase_cnt AS user_average
FROM `uplifted-sphinx-439401-k5.modulabs_project.user_rf` rf
LEFT JOIN (
-- 고객 별 총 지출액
SELECT
    CustomerID,
    round(sum(Quantity*UnitPrice)) AS user_total
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID
) ut
ON rf.CustomerID = ut.CustomerID;
```



### RFM 통합 테이블 출력하기

• 최종 user\_rfm 테이블을 출력하기

```
/*RFM 통합 테이블 출력*/
SELECT *
FROM `uplifted-sphinx-439401-k5.modulabs_project.user_rfm`
```



# 11-8. 추가 Feature 추출

## 1. 구매하는 제품의 다양성

```
• 1) 고객 별로 구매한 상품들의 고유한 수를 계산하기
2)
user_rfm 테이블과 결과를 합치기
3)
user_data 라는 이름의 테이블에 저장하기

CREATE OR REPLACE TABLE `uplifted-sphinx-439401-k5.modulabs_project.user_data` AS

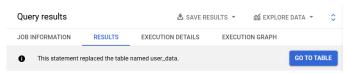
WITH unique_products AS (
SELECT
CustomerID,
COUNT(DISTINCT StockCode) AS unique_products
```

```
FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
GROUP BY CustomerID
)

SELECT ur.*, up.* EXCEPT (CustomerID)

FROM `uplifted-sphinx-439401-k5.modulabs_project.user_rfm` AS ur

JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```



#### 2. 평균 구매 주기

- 고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)
  - 평균 구매 소요 일수를 계산하고, 그 결과를 user\_data 에 통합

```
-- 평균 구매 소요 일수를 계산
-- 결과를 user_data에 통합
CREATE OR REPLACE TABLE `uplifted-sphinx-439401-k5.modulabs_project.user_data` AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
   CustomerID,
   CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_in
terval
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
     CustomerID,
     DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DA
Y) AS interval_
      `uplifted-sphinx-439401-k5.modulabs_project.data`
   WHERE CustomerID IS NOT NULL
 GROUP BY CustomerID
)
SELECT u.*, pi.* EXCEPT (CustomerID)
FROM `uplifted-sphinx-439401-k5.modulabs_project.user_data` AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```



#### 3. 구매 취소 경향성

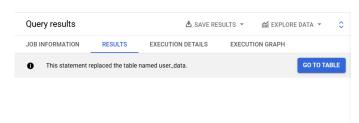
• 고객의 취소 패턴 파악하기

1) 취소 빈도(cancel\_frequency) : 고객 별로 취소한 거래의 총 횟수

2) 취소 비율(cancel\_rate): 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율

 취소 빈도와 취소 비율을 계산하고 그 결과를 user\_data 에 통합하기 (취소 비율은 소수점 두번째 자리)

```
-- 취소 빈도와 취소 비율을 계산
-- 결과를 user_data에 통합
-- 취소 비율은 소수점 두번째 자리까지 구하기
{\tt CREATE~OR~REPLACE~TABLE~`uplifted-sphinx-439401-k5.modulabs\_project.user\_data`~AS}
WITH TransactionInfo AS (
 SELECT
   CustomerID,
   count(DISTINCT InvoiceNo) AS total_transactions,
   countif(DISTINCT InvoiceNo LIKE 'C%') AS cancel_frequency
 FROM `uplifted-sphinx-439401-k5.modulabs_project.data`
 GROUP BY CustomerID
)
SELECT u.*, t.* EXCEPT(CustomerID), round(cancel_frequency / total_transactions* 100, 2) AS cancel_ra
FROM `uplifted-sphinx-439401-k5.modulabs_project.user_data` AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;
```



• 다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 user\_data 를 출력하기

SELECT \*
FROM `uplifted-sphinx-439401-k5.modulabs\_project.user\_data`



## 회고

중간중간에 데이터를 잘못 추출한 경우가 생겨 되돌려야할 때가 있었습니다. 코드를 정확히 작성하고 데이터를 백업해놓는 것이 중요함을 느꼈습니다.